

Principaux algorithmes de Machine Learning

Aide-mémoire de sélection — par type de problème · Marianne A. · usage formation (M4 & réutilisable)

Comment lire cette fiche. On choisit d'abord le *type de problème* (prédire une valeur → régression ; une catégorie → classification ; regrouper sans étiquette → non supervisé), puis une *famille* de modèles. Les colonnes donnent, pour chaque algo, à quoi il sert, ses forces et ses limites. C'est une **heuristique de départ**, pas une vérité : la bonne pratique reste de faire concourir 2-3 familles complémentaires sur vos données et de comparer.

Trio M4B1 Le repère vert signale les trois familles retenues comme socle sur données tabulaires : un **linéaire régularisé** (baseline interprétable), un **ensemble par bagging** (robuste) et un **boosting** (performance). Elles balaient le spectre biais-variance, ce qui rend la comparaison instructive.

- Modèles linéaires
- Arbres & ensembles
- Autres modèles supervisés
- Clustering
- Réduction de dimension
- Association

APPRENTISSAGE SUPERVISÉ — ON DISPOSE D'UNE CIBLE ÉTIQUETÉE (Y CONNU)

Modèles linéaires

ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
Régression linéaire Régression	Modélise une relation linéaire entre des variables d'entrée et une sortie numérique continue.	- Prix immobilier - Prévision de ventes / CA - Valeur vie client	- Explicable, coefficients lisibles - Très rapide à entraîner - Référence de base idéale	- Suppose la linéarité - Sensible aux valeurs aberrantes - Sous-apprend en petite dim. élevée
Régression logistique Classification	Modèle linéaire dont la sortie est une <i>probabilité</i> de classe (0/1, ou multi-classe).	- Score de risque crédit - Prédiction de churn - Détection spam	- Interprétable - Peu de surapprentissage avec régularisation - Multi-classe possible	- Suppose une frontière linéaire - Surapprend en petite dim. élevée
Régression Ridge (L2) Régression / Classification TRIO M4B1	Pénalise les coefficients peu utiles en les rapprochant de zéro (régularisation L2). Version classif : <i>RidgeClassifier</i> .	- Maintenance prédictive - Prévision de revenus - Baseline tabulaire	- Moins de surapprentissage - Gère la multicollinéarité - Explicable & rapide	- Garde tous les prédicteurs - Pas de sélection de variables - Reste linéaire
Régression Lasso (L1) Régression / Classification	Régularisation L1 : met à zéro les coefficients inutiles → fait une <i>sélection</i> de variables.	- Prix immobilier - Données de santé (haute dim.) - Modèles parcimonieux	- Moins de surapprentissage - Gère la haute dimension - Sélection automatique de variables	- Interprétabilité fragile si variables corrélées - Choix instable entre variables liées

ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
Elastic Net Régression / Classification	Combine L1 + L2 : sélection de variables (Lasso) tout en gérant les groupes corrélés (Ridge).	• Génomique / haute dimension • Marketing, scoring	• Compromis robuste Ridge/Lasso • Stable avec variables corrélées	• Deux hyperparamètres à régler • Reste un modèle linéaire
■ Modèles à base d'arbres & ensembles				
ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
Arbre de décision Classif. / Régression	Enchaîne des règles de décision sur les variables pour produire une prédiction.	• Prédiction de churn • Scoring crédit • Aide au diagnostic	• Explicable et visualisable • Gère valeurs manquantes • Peu de préprocessing	• Surapprend facilement • Sensible aux valeurs aberrantes • Instable (petit changement → autre arbre)
Forêt aléatoire (Random Forest) Classif. / Régression · bagging TRIO M4B1	Ensemble qui moyenne de nombreux arbres décorrélés (bagging) pour réduire la variance.	• Scoring crédit • Prix immobilier • Référence non-linéaire	• Réduit le surapprentissage • Robuste, peu de réglage • Capte interactions & non-linéarités	• Peu interprétable • Modèle lourd (mémoire) • Souvent battu par le boosting
HistGradientBoosting Classif. / Régression · boosting TRIO M4B1	Boosting d'arbres de scikit-learn accéléré par <i>binning</i> en histogrammes. Souvent l'état de l'art sur tabulaire.	• Scoring / risque • Prédiction de demande • Compétitions tabulaires	• Très bonne performance sur tabulaire • Rapide, passe à l'échelle • Gère nativement les NaN	• Moins interprétable • Réglage plus fin que RF • Peut surapprendre sans validation
Gradient Boosting (classique) Classif. / Régression · boosting	Construit des arbres séquentiellement, chacun corrigeant les erreurs du précédent.	• Prévision d'émissions • Tarification	• Bonne précision • Gère non-linéarités & multicollinéarité	• Sensible aux aberrants → surapprentissage • Coûteux, lent (version historique)
XGBoost Classif. / Régression · boosting	Implémentation de gradient boosting efficace et très optimisée, régularisée.	• Prédiction de churn • Traitement de sinistres (assurance)	• Résultats précis • Capte les relations non linéaires • Régularisation intégrée	• Réglage d'hyperparamètres complexe • Moins bon sur données très éparées • Dépendance externe
LightGBM Classif. / Régression · boosting	Framework de boosting conçu pour la vitesse et la faible empreinte mémoire (croissance <i>leaf-wise</i>).	• Gros volumes de données • Prédiction de délais, de niveaux	• Très rapide, gros volumes • Faible usage mémoire	• Peut surapprendre (leaf-wise) • Réglage délicat sur petits jeux
■				

Autres modèles supervisés				
ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
SVM (machine à vecteurs de support) Classif. / Régression	Cherche la frontière (marge maximale) qui sépare le mieux les classes ; le noyau permet le non-linéaire.	• Classification de texte • Reconnaissance d'images • Petits jeux à haute dim.	• Efficace en haute dimension • Noyaux → frontières non linéaires	• Ne passe pas à l'échelle (gros N) • Réglage noyau/C sensible • Peu interprétable
k plus proches voisins (k-NN) Classif. / Régression	Prédit selon les k exemples les plus proches dans l'espace des variables. Aucun « apprentissage » réel.	• Systèmes de recommandation • Imputation • Baseline simple	• Très simple, aucun entraînement • Capte des frontières complexes	• Lent à la prédiction (gros N) • Sensible à l'échelle & au bruit • Souffre de la haute dimension
Naïve Bayes Classification	Classifieur probabiliste basé sur le théorème de Bayes, en supposant l'indépendance des variables.	• Filtrage anti-spam • Analyse de sentiment • Classification de texte	• Extrêmement rapide • Efficace sur le texte • Marche avec peu de données	• Hypothèse d'indépendance irréaliste • Probabilités mal calibrées
Réseaux de neurones (MLP / deep) Classif. / Régression	Couches de neurones apprenant des représentations. Incontournables sur images, texte, signal.	• Vision, NLP, audio • Séries temporelles complexes	• Capte des relations très complexes • État de l'art sur données non structurées	• Gourmand en données & calcul • « Boîte noire » • Souvent inutile sur tabulaire

APPRENTISSAGE NON SUPERVISÉ — PAS DE CIBLE ; ON CHERCHE UNE STRUCTURE DANS LES DONNÉES				
■ Clustering (regroupement)				
ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
K-Means Partitionnement	Forme K groupes en minimisant les distances euclidiennes aux centres. Le plus utilisé.	• Segmentation client • Recommandation • Compression d'images	• Passe à l'échelle • Simple à implémenter/interpréter • Clusters compacts	• K fixé à l'avance • Suppose des clusters sphériques • Gère mal tailles/densités variées
Clustering hiérarchique Agglomératif	Approche ascendante : chaque point est un cluster, puis on fusionne les plus proches itérativement.	• Détection de fraude • Regroupement de documents	• Pas besoin de fixer le nb de clusters • Dendrogramme informatif	• Pas toujours le meilleur découpage • Inadapté aux gros volumes (coûteux)
DBSCAN Par densité	Regroupe les points par densité ; isole automatiquement le bruit / les points aberrants.	• Détection d'anomalies • Données géospatiales	• Nb de clusters non fixé • Formes arbitraires • Gère le bruit	• Sensible aux paramètres (eps) • Difficile si densités très variées

ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
Modèles de mélange gaussien (GMM) Probabiliste	Modélise les données comme un mélange de lois normales ; affecte une probabilité d'appartenance.	• Segmentation client • Recommandation • Clusters chevauchants	• Probabilité d'appartenance • Clusters qui se recouvrent • Plus fin que K-Means	• Réglage complexe • Nb de composantes à fixer
■ Réduction de dimension				
ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
ACP (PCA) Linéaire	Projette les données sur les axes de plus grande variance pour réduire le nombre de variables.	• Compression / débruitage • Pré-traitement avant modèle • Visualisation	• Rapide, simple • Réduit le bruit & la redondance	• Composantes peu interprétables • Ne capte que le linéaire
t-SNE / UMAP Non linéaire · visualisation	Projettent en 2D/3D en préservant la structure locale ; surtout pour <i>voir</i> les données.	• Visualisation de clusters • Exploration de données	• Excellentes cartes 2D • UMAP rapide & préserve mieux le global	• Pas pour du feature engineering fiable • Résultats sensibles aux paramètres
■ Règles d'association				
ALGORITHME	DESCRIPTION	APPLICATIONS	AVANTAGES	INCONVÉNIENTS
Apriori Itemsets fréquents	Identifie les ensembles d'articles fréquents et en déduit des règles « si A alors B ».	• Placement produits (panier) • Moteurs de recommandation • Optimisation de promotions	• Résultats intuitifs & interprétables • Exhaustif (support & confiance)	• Génère beaucoup de règles inutiles • Coûteux en calcul/mémoire • Itemsets redondants

Rappel méthodo. Ces recommandations sont des règles de pouce — un point de départ. Sur données tabulaires, le réflexe sain est de comparer une baseline linéaire régularisée (Ridge/ Lasso), un ensemble robuste (Random Forest) et un boosting (HistGradientBoosting / XGBoost / LightGBM), puis de trancher sur une métrique adaptée au problème et à une validation honnête. · Structure inspirée de l'aide-mémoire « Top ML Algorithms » (DataCamp), enrichie et traduite.