

Interprétabilité & XAI

Expliquer POURQUOI un modèle prédit · Marianne A. · confiance métier & conformité (AI Act)

Pourquoi expliquer ? Expliquer les prédictions est exigé pour la **confiance métier** et la **conformité** (AI Act, transparence). Deux voies possibles : des modèles *intrinsèquement interprétables*, ou des méthodes *post-hoc* appliquées à des boîtes noires.

Distinction Interprétabilité **GLOBALE** (comment le modèle se comporte en général) vs **LOCALE** (pourquoi *CETTE* prédiction).

1 Deux familles

APPROCHE	EXEMPLES	AVANTAGE / LIMITE
Intrinsèque le modèle s'explique lui-même	Régression linéaire / logistique (coefficients), arbre de décision (règles).	Transparent : l'explication est le modèle lui-même ; parfois moins performant.
Post-hoc expliquer une boîte noire	Feature importance, SHAP, LIME, PDP appliqués à RF / boosting / réseaux de neurones.	S'applique à tout modèle ; mais l'explication reste approximative .

2 Les méthodes post-hoc

MÉTHODE	CE QUE ÇA DONNE	PORTÉE	À SAVOIR
Importance des variables (permutation)	Importance globale de chaque variable pour le modèle.	Globale	Préférer la permutation à l'importance par impureté (biaisée par la cardinalité).
SHAP	Contribution de chaque variable à chaque prédiction (théorie des jeux).	Globale + locale	Référence , mais coûteux en calcul.
LIME	Approxime localement la boîte noire par un modèle simple autour d'une prédiction.	Locale	Rapide mais instable (varie selon l'échantillonnage).
PDP / ICE	Effet marginal d'une variable sur la prédiction.	Globale	Trompeur si variables corrélées (suppose l'indépendance).

3 Global vs local : quand utiliser quoi

GLOBAL

comment le modèle se comporte en général

LOCAL

pourquoi CETTE prédiction précise

BESOIN	NIVEAU	OUTIL
Comprendre les facteurs dominants du modèle.	Global	Importance de permutation, SHAP (résumé).
Justifier une décision individuelle (ex : refus de crédit).	Local	SHAP (valeurs locales), LIME.
Voir l'effet d'une variable.	Global	PDP / ICE.

4 Pièges

LE PIÈGE	LA RÉALITÉ
Importance par impureté	Biaisée vers les variables à forte cardinalité → utiliser la permutation .
Corrélation $\neq$ causalité	Une variable « importante » n'est pas forcément une cause → prudence dans les conclusions.
LIME instable	Deux exécutions peuvent différer → vérifier la robustesse.
PDP avec variables corrélées	Effets trompeurs → croiser avec ICE / SHAP.
« Interprétable » $\neq$ « correct »	Un modèle explicable peut être faux ; l'interprétabilité ne remplace pas l'évaluation.

Note conformité. L'AI Act impose de la **transparence** : informer l'utilisateur qu'il interagit avec une IA, et documenter les systèmes à haut risque. L'explicabilité y contribue directement.

La règle d'or. Si l'explicabilité est **cruciale** (réglementaire, décision sensible), privilégier un modèle *intrinsèquement interprétable* · sinon, expliquer la boîte noire avec **SHAP** (global + local), en gardant à l'esprit que ces explications restent des *approximations*.

À retenir. Interprétable par construction quand la décision l'exige, boîte noire expliquée par SHAP sinon — global pour comprendre le modèle, local pour justifier une prédiction, sans jamais confondre explicabilité et exactitude. **Fiche 10/12 · Série ML**